

Tahmin Performansına ve Belirsizliğine Değişken Katkılarının Açıklanması:

Tahmin ve Belirsizlik Açısından Önemli Değişkenler Aynı mı?



Elif Kartal | Doç. Dr. Mustafa Çavuş

Eskişehir Teknik Üniversitesi, İstatistik Bölümü



ds.elifkartal@gmail.com | mustafacavus@eskisehir.edu.tr

GİRİŞ


BELİRSİZLİK

UNCERTAINTY

Bir modelin tahminlerinin ne kadar güvenilir olduğunu veya tahmin yaparken ne kadar "emin" olmadığını ifade eder (Gal & Ghahramani, 2016).

Belirsizliğin varlığını bilirsek;


- riskli tahminler belirlenebilir,
- model güvenilirliği değerlendirilebilir,
- ve karar süreçleri daha kontrollü hale getirilebilir.



KONFORMAL TAHMİN

CONFORMAL PREDICTION


Tahmin modellerine istatistiksel kapsama garantisi sunarak güvenilir tahmin aralıkları ekleyen dağılımdan bağımsız bir yöntemdir (Vovk ve ark., 2005).



KONFORMAL KANTİL REGRESYONU

CONFORMALIZED QUANTILE REGRESSION

Kantil regresyon tahminlerini conformal prediction yaklaşımla kalibre ederek dağılımdan bağımsız ve değişen varyansa uyumlu güvenilir tahmin aralıkları üreten bir tahmin yöntemidir. (Romano ve ark., 2019)



Uygunluk Skoru (Conformity Score):

$$S_i = \max Q_y (\alpha / 2 | x_i) - y_i , y_i - Q_y (1 - \alpha / 2 | x_i)$$

Final Tahmin Seti:

$$C (X_{n+1}) = Q_y (\alpha / 2 | X_{n+1}) - q , Q_y (1 - \alpha / 2 | X_{n+1}) + q$$


AÇIKLANABİLİR YAPAY ZEKA

EXPLAINABLE ARTIFICIAL INTELLIGENCE

Açıklanabilir Yapay Zeka, karmaşık makine öğrenmesi modellerinin iç işleyişini ve verdikleri kararların arkasındaki nedenleri insan algısına uygun bir çerçeveye oturtmayı amaçlayan yöntemler bütünüdür.

- LIME
- SHAP
- Permutation Feature Importance
- Partial Dependence Plot

Açıklanabilir yapay zeka yöntemlerinden bazılarıdır
(Arrieta ve ark., 2020).




PERMÜTASYONEL ÖZELLİK ÖNEMİ

PERMUTATIONAL FEATURE IMPORTANCE

Permütasyonel Özellik Önemi (PFI), belirli bir özelliğin değerlerini rastgele karıştırarak model performansındaki düşüşü ölçen ve bu sayede o özelliğin tahmin üzerindeki etkisini belirleyen modelden bağımsız bir yöntemdir(Breiman, 2001).

$$PFI_j = \frac{1}{R} \sum_{r=1}^R \left(L(y_{test}, \hat{y}_{j,perm}^{(r)}) - L(y_{test}, \hat{y}) \right)$$




Kaynak: <https://medium.com/responsibleml/basic-xai-with-dalex-part-2-permutation-based-variable-importance-1516c2924a14>

BELİRSİZLİK PERMÜTASYONEL ÖZELLİK ÖNEMİ

UNCERTAINTY PERMUTATIONAL FEATURE IMPORTANCE

Belirsizlik için PFI, bir değişkenin rastgele karıştırılması sonrası tahmin aralıklarının genişliğinde meydana gelen değişimi ölçerek, ilgili değişkenin model belirsizliğine olan katkısını değerlendiren açıklanabilirlik yöntemidir (Mehdiyev ve ark., 2025).



| YÖNTEM



Tahmin PFI

Özniteliklerin nokta tahmin doğruluğu üzerindeki etkisi. Hangi değişkenler başarıyı belirler?



Belirsizlik PFI

Özniteliklerin güven aralığı genişliği üzerindeki etkisi. Hangi değişkenler belirsizliği tetikler?



Karşılaştırma

Spearman ve Kendall korelasyonları ile hiyerarşik uyumun testi. Top 5 değişken çakışma analizi.




VERİ SETLERİ

Araştırma deneylerinde OpenML veritabanından seçilen, farklı özelliklere sahip 9 regresyon veri seti kullanıldı.

Veri Seti	Örnek Sayısı	Özellik Sayısı	Örnek / Özellik Oranı	Eksik Veri Oranı	Hedef Varyansı	Tekrarlılık	İçsel Boyut	Yerel Varyans
abalone	0.369	0.110	0.091	0.000	0.082	1.000	0.000	0.081
airfoil_self_noise	0.100	0.000	0.031	0.000	0.145	0.109	0.167	0.148
auction_verification	0.180	0.000	0.051	0.000	0.788	0.000	0.167	0.786
concrete_compressive_strength	0.000	0.155	0.000	0.000	0.222	0.094	0.500	0.221
physiochemical_protein	1.000	0.195	1.000	0.000	0.135	0.636	0.167	0.135
superconductivity	0.798	1.000	0.032	0.000	0.285	0.258	0.833	0.273
fifa	0.771	0.589	0.128	0.000	0.843	0.503	0.500	0.823
white_wine	0.411	0.265	0.066	0.000	0.000	0.055	1.000	0.000
california_housing	0.790	0.155	0.489	0.000	1.000	0.235	0.167	1.000

Karşılaştırma kolaylığı adına karmaşıklık metrikleri min max normalizasyonu ile normalize edilmiştir.

| VERİ SETİ BÖLÜMÜ VE PARAMETRELER



Lineer Model | Rasgele Orman | XGBoost

Modeller varsayılan parametrelerle eğitilmiştir.

PFI permutasyon değeri $B=50$

Konformal hata payı $\alpha = 0.10$

BULGULAR

MODEL PERFORMANSLARI

	Lineer Model	Rastgele Orman	XGBoost
Ortalama R ²	 0.47	 0.75	 0.76
Ortalama Normalize Edilmiş Aralık Genişliği	 0.38	 0.37	 0.34
Ortalama Kapsama Oranı	 0.90	 0.91	 0.89

| VERİ SETİ VE MODEL BAZINDA KORELASYON METRİKLERİ

- Aynı veri setinde modeller farklı düzeyde ilişki göstermektedir.
- Tahmin için önemli değişkenler, belirsizlik için de önemli olabilir ancak önem sıraları değişebilir.
- Bazı durumlarda tahmin ve belirsizliği etkileyen değişkenler farklılaşmaktadır.
- Veri seti yapısı, tahmin -belirsizlik değişken önemleri ilişkisini doğrudan etkilemektedir







	abalone			airfoil_self_noise			auction_verification		
İlk 5 Örtüşme	0.80	0.80	0.40	1.00	1.00	1.00	0.80	1.00	0.60
Spearman	0.98	0.86	0.40	0.10	0.40	-0.80	0.45	0.90	0.67
Kendall	0.93	0.64	0.29	0.00	0.40	-0.60	0.36	0.79	0.50
	california_housing			concrete_compressive_strength			fifa		
İlk 5 Örtüşme	0.80	0.80	0.60	0.80	0.80	0.60	0.60	0.80	0.00
Spearman	0.55	0.71	0.10	0.81	0.76	-0.12	0.61	0.33	-0.19
Kendall	0.43	0.50	0.07	0.64	0.57	-0.07	0.44	0.23	-0.10
	physiochemical_protein			superconductivity			white_wine		
İlk 5 Örtüşme	0.80	0.60	0.40	0.80	0.40	0.00	0.60	0.80	0.40
Spearman	0.77	0.43	-0.60	0.45	0.70	-0.08	0.29	0.88	-0.21
Kendall	0.61	0.33	-0.44	0.32	0.53	-0.05	0.24	0.71	-0.16
	LM	RF	XGBOOST	LM	RF	XGBOOST	LM	RF	XGBOOST

MODEL VE KARMAŞIKLIK ÖLÇÜLERİ BAZINDA KORELASYON METRİKLERİ


- Gözlem ve değişken sayısı arttıkça tahmin–belirsizlik değişken önemleri ilişkisi azalmaktadır.
- Özellikle RF modelinde içsel boyutun artması açıklamaların daha fazla ayrışmasına neden olabilmektedir.
- Veri seti karmaşıklığı arttıkça tahmin ve belirsizlik davranışları birbirinden uzaklaşabilmektedir.

LM						
İlk 5 Örtüşme	-0.14	-0.70	-0.22	-0.45	-0.86	-0.05
Spearman	-0.13	-0.39	0.30	0.13	-0.03	0.45
Kendall	-0.13	-0.39	0.30	0.13	-0.03	0.45
RF						
İlk 5 Örtüşme	-0.15	-0.22	-0.42	-0.77	-0.60	-0.24
Spearman	-0.85	-0.12	-0.02	-0.12	-0.13	0.03
Kendall	-0.90	-0.15	-0.20	-0.37	-0.29	-0.02
XGBOOST						
İlk 5 Örtüşme	-0.15	-0.17	-0.43	-0.62	-0.71	-0.60
Spearman	-0.05	0.29	-0.33	-0.35	-0.22	-0.70
Kendall	-0.07	0.36	-0.34	-0.32	-0.17	-0.74
	Hedef Varyansı	İçsel Boyut	Örnek / Özellik Oranı	Örnek Sayısı	Özellik Sayısı	Tekrarlılık
						Yerel Varyans

| TAHMİN VE BELİRSİZLİK PFI AÇIKLAMALARI: airfoil_self_noise veri seti



SONUÇ VE ÖNERİLER



KAYNAKLAR

Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Gal, Y., & Ghahramani, Z. (2016). Dropout as a Bayesian approximation: Representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning* (Vol. 48, pp. 1050–1059). *Proceedings of Machine Learning Research*. [PMLR Proceedings Page](#)

Mehdiyev, N., Majlatow, M., Fettke, P., 2025. Integrating permutation feature importance with conformal prediction for robust Explainable Artificial Intelligence in predictive process monitoring. *Eng. Appl. Artif. Intell.* 149, 110363.

Romano, Y., Patterson, E., & Candes, E. (2019). Conformalized quantile regression. *Advances in neural information processing systems*, 32.

Vovk, V., Gammerman, A., Shafer, G., 2005. *Algorithmic learning in a random world*, Vol. 29. vol. 29, Springer.

TEŞEKKÜRLER



Veri Setleri | Kod Dosyaları

✉ Elif Kartal | ds.elifkartal@gmail.com